

İSTANBUL SABAHATTİN ZAİM ÜNİVERSİTESİ

Mühendislik ve Doğa Bilimleri Fakültesi

Bilgisayar Mühendisliği Bölümü

BİM 320 – Görüntü İşleme

PROJE RAPORU

Otopark Doluluk Tespit Sistemi

Ömer Faruk Erdoğan – 030123009

Semih Kantar – 030123014

Fatih Enes Bakır - 030123018

Dr. Öğr. Üyesi Hasibe Büşra AYTEKİN

Mayıs 2026

1. Özet

Projemiz özet olarak otopark alanlarının çoğu zaman dolu olması ve bunun önceden tespit edilemeyip otoparkın içerisinde sıkışıklığa yol açması problemine çözüm bulmayı hedeflemiştir. Bu bağlamda sadece klasik görüntü işleme teknikleri kullanılarak otopark doluluk tespiti yapan bir sistem geliştirilmiştir. Projede makine öğrenmesi veya derin öğrenme yöntemleri kullanılmamış yalnızca OpenCV kütüphanesi tabanlı klasik görüntü işleme tekniklerinden yararlanılmıştır.

Projede Kaggle üzerinden eriştiğimiz PKLot veri seti kullanılmıştır. Veri setinde bulunan .json uzantılı annotation dosyaları kullanılarak görüntü içerisindeki park alanları görüntünün geri kalanından ayrılmış ve her bir park alanı bağımsız olarak işlenmiştir. Bu işlem sonrasında sırasıyla gri seviye dönüşümü, Gaussian Blur ve Canny kenar tespiti uygulanmıştır

Projenin asıl karar verme ve tespit etme süreci kenar tespiti aşamasından sonra gerçekleşmektedir. Bu bağlamda her bir park alanı için kenar yoğunluğu hesaplanmış ve belirlenen threshold değerine göre bu değerin üstünde olan park alanları dolu, altında olanlar ise boş olarak işaretlenmiştir. Final threshold değeri belirlenene kadar farklı threshold değerleri hem tek bir örnek görüntü üzerinden hem de bütün veri seti üzerinden test edilmiştir. Bu yapılan testler sonucu mevcut veri setinde en iyi threshold değeri 25 olarak belirlenmiştir.

Projenin oluşturulma aşamasında veri setinden rastgele seçilmiş birkaç örnek görüntü üzerinde yüksek doğruluk oranı elde edilmesine rağmen görüntülerin dengesiz dağılıma sahip olduğu ve bunun yanıltıcı sonuçlar oluşturabileceği fark edilmiştir. Bu nedenle boş ve dolu park alanlarının daha dengeli olduğu görüntüler seçilmiş ve algoritma yeniden test edilmiştir. Ayrıca kenar yoğunluğu yöntemine ek olarak görüntünün parlaklık değeri de karar verme sürecine eklenmeye çalışılmış ancak yapılan testlerde bu yaklaşımın doğruluk oranını düşürdüğü görülmüş ve sistemden çıkarılmıştır.

Sonuç olarak final testinde sistem yaklaşık %83 doğruluk oranına ulaşmıştır. Bunun yanında precision, recall ve F1-score gibi değerlendirme metrikleri de hesaplanmış ve sistemin özellikle dolu park alanlarını tespit etmede başarılı sonuçlar verdiği gözlemlenmiştir. Elde edilen sonuçlar klasik görüntü işleme yöntemlerinin uygun veri seti ve doğru parametre seçimleri ile otopark doluluk tespiti probleminde başarılı şekilde kullanılabileceğini göstermiştir. Bununla birlikte kamera açılarındaki farklılıklar, ışık değişimleri ve veri setindeki eksik etiketlemeler sistemin performansını etkileyebilecek başlıca sınırlılıklar olarak değerlendirilmiştir.

Projenin daha da geliştirilmesi, gerçek hayata daha uyumlu hale gelmesi kapsamında sistemin gerçek zamanlı kamera görüntüleri üzerinde çalıştırılması ve otopark alanlarındaki sistemlere entegre edilmesi planlanabilir. Aynı zamanda gelecekte yapılabilecek geliştirmeler arasında farklı iklim koşullarına sahip coğrafyalarda ve gece çekilmiş görüntüler üzerinde sistemin performansının test edilmesi planlanabilir. Kenar yoğunluğu yerine daha farklı görüntü işleme tekniklerinin birlikte kullanılması ve farklı veri setleri ile sistemin doğruluk oranı daha da artırılabilir. Bununla birlikte klasik görüntü işleme tekniklerinin, özellikle veri setinin daha da büyüdüğü ve görüntülerin karmaşıktığı durumlarda yetersiz kalabileceği anlaşılmıştır.

2. Giriş

2.1 Problem Tanımı

Günümüzde, özellikle büyük şehirlerde nüfus artışına bağlı olarak araç sayısının ciddi oranda artması, otopark alanlarında yoğunluğa ve sıkışıklığa yol açmaktadır. Araç sürücülerinin otopark alanına girmeden otoparkın içerisindeki boş park alanları sayısını ve yerini bilmemesi bu sıkışıklık ve yoğunluğun ana sebebidir. Özellikle alışveriş merkezleri, üniversiteler ve hastaneler gibi yoğun araç giriş çıkışının olduğu alanlarda bu problemler daha belirgin hale gelmektedir.

Otopark alanlarının doluluk durumunun manuel olarak takip edilmesi hem zor hem de verimsiz bir yöntemdir. Bu nedenle otopark alanlarının içerisinde ne kadar boş yer kaldığının, hangi park alanlarının dolu hangilerinin boş olduğunun otomatik şekilde tespit edilmesi günümüzde önemli bir ihtiyaç haline gelmiştir. Bu problemin çözülmesi sayesinde sürücüler boş park alanlarına daha hızlı yönlendirilebilmekte ve otoparklar içerisindeki yoğunluk azaltılabilmektedir.

2.2 Gerçek Dünya Bağlamı ve Motivasyon

Teknolojinin hızla gelişmesi ile birlikte akıllı sistemler ve görüntü işleme temelli sistemler günlük yaşamın birçok alanında aktif bir şekilde kullanılmaktadır. Özellikle evlerdeki güvenlik sistemleri, trafik yönetimi, yüz tanıma ve nesne tespiti gibi alanlarda görüntü işleme teknikleri yaygın şekilde kullanılmaktadır. Otopark doluluk tespiti problemi de görüntü işleme yöntemlerinin gerçek hayatta uygulanabileceği önemli alanlardan biridir.

Otopark sistemlerinde sensör tabanlı gelişmiş teknolojik yöntemler kullanılabilmesine rağmen bu sistemlerin ek donanım maliyeti ve bakım zorluğu gibi çeşitli dezavantajları vardır. Otoparklarda kullanılabilecek kamera görüntülerinin işlenmesine dayalı sistemler ise hali hazırda mevcut kamera altyapıları kullanılarak daha düşük maliyetle ve daha düşük eforla uygulanabilmektedir. Bu nedenle görüntü işleme tabanlı sistemler bu konuda hem ekonomik hem de geliştirilebilir alternatif çözümler sunmaktadır.

Günlük hayatımızın her anında hissettiğimiz bu büyük gerçek dünya probleminin sadece klasik görüntü işleme teknikleri kullanılarak çözülebilmesi ihtimali bu projedeki ana motivasyonlarımızdan birisi olmuştur. Bu çözümün alternatif diğer çözümlere göre çok daha eforsuz ve hızlı olması aynı şekilde projedeki motivasyonlarımızdan biridir.

2.3 Projenin Amacı ve Kapsamı

Bu projenin temel amacı, otopark görüntülerindeki park alanlarının dolu veya boş olduğunu yalnızca klasik görüntü işleme yöntemleri kullanarak tespit eden bir sistem geliştirmektir. Burada sistem hem sayma hem de sınıflandırma işlemini yapmaktadır. Bu projede makine öğrenmesi ve derin öğrenme yöntemleri kullanılmamış tüm karar mekanizması klasik görüntü işleme teknikleri üzerine kurulmuştur.

3. Literatür Özeti

3.1 PKLot Makale İncelemesi

Almeida ve arkadaşları (2015) tarafından yapılan bu çalışma, otopark doluluk tespiti alanında literatürdeki en kapsamlı referans kaynaklarından biri olarak kabul edilmektedir.

Brezilya'daki iki farklı üniversite otoparkından (UFPR ve PUCPR) üç farklı kamera açısı kullanarak PKLot adı verilen çok büyük bir veri seti toplamışlardır. Algoritmaların dış ortama dayanıklılığını test etmek için bu görüntüler güneşli, bulutlu ve yağmurlu olmak üzere üç farklı hava koşulunda çekilen toplam 695.899 park yeri görüntüsünden oluşmaktadır.

Yöntem olarak araçların renk çeşitliliğinden etkilenmemek adına park alanlarındaki yüzey dokularının değişimini inceleyen LBP (Local Binary Patterns) ve LPQ (Local Phase Quantization) gibi klasik öznitelik çıkarım filtreleri kullanılmış bu veriler daha sonra SVM (Destek Vektör Makineleri) sınıflandırıcısı ile test edilmiştir. Deneysel sonuçlara bakıldığında modelin eğitildiği kamera açısı ile test edildiği yer aynı tutulduğunda %99'un üzerinde oldukça yüksek bir doğruluk oranı elde edilmiştir. Ancak sistem eğitim esnasında hiç kullanılmayan yabancı bir otopark ortamında test edildiğinde doku tabanlı bu klasik yöntemin doğruluğu %89 seviyelerine gerilemiştir. Araştırmacılar bu düşüşün nedenini açık alanlardaki ani ışık değişimlerinin ve ağaç ya da bina gölgelerinin doku piksellerini bozarak algoritmanın kafasını karıştırmasına bağlamışlardır. Hava bulutlandığında veya güneşin açısı değiştiğinde oluşan yapay çizgiler, sistemin boş yerleri dolu, dolu yerleri de boş zannetmesine yol açmıştır.

Makalede görüntü tabanlı bu tarz klasik çözümlerin fiziksel sensör kurulumlarına kıyasla büyük otoparklarda ciddi bir maliyet avantajı sunduğu özellikle vurgulanmaktadır.

3.2 Komşu Park Alanlarının İlişisini İnceleyen Markov Random Field (MRF) yaklaşımı

Wu ve arkadaşları (2007) tarafından yapılan çalışmada otopark doluluk tespiti yapılırken sadece tek bir park alanına odaklanmak yerine yan yana duran komşu park yerlerinin birbiriyle olan ilişkisi incelenmiştir. Araştırmacılar, tek bir park yerine tek başına bakıldığında ağaç gölgeleri veya araçların birbirini gölgelemesi yüzünden sistemlerin çok sık hata yaptığını görmüşlerdir. Bu sorunu çözmek için üçerli park yerlerinden oluşan küçük

resim parçaları kesmişlerdir ve eğik kamera açılarını düzeltmek için perspektif dönüşümü uygulamışlardır.

Sistemde her üçlü park alanının doluluk durumu (boş=0, dolu=1) şeklinde 3 bitlik kodlarla ifade edilmiş ve toplam 8 farklı senaryo tanımlanmıştır. Otopark zemininin renk dağılımını ölçmek için bir Gaussian Zemin Renk Modeli kurulmuş, her alandan toplanan 215 farklı özellik PCA yöntemiyle 50'ye düşürülmüştür. Sınıflandırma kısmında 8 sınıflı bir SVM algoritması kullanılmıştır. Komşu alanlar birbirleriyle ortak park yerleri paylaştığı için ortaya çıkan karar çelişkilerini gidermek adına Markov Random Field (MRF) tabanlı bir düzeltme mekanizması geliştirilmiştir. MRF yapısı, hatalı ve tutarsız etiketlemeleri matematiksel bir enerji fonksiyonuyla en aza indirerek düzeltmektedir.

DeneySEL sonuçlara bakıldığında, tek bir park alanına bakan klasik SVM modeli %84,35 doğruluk verirken, üçlü alanları inceleyen SVM modeli %85,57 başarı göstermiştir. Sisteme MRF algoritması da dahil edildiğinde ise toplam doğruluk oranı %93,52'ye yükselmiştir, hatalı kararlar %7,32'den %2,57'ye düşmüştür. Yanlış kabul oranı (FAR) %1,25'e, yanlış ret oranı (FRR) ise %3,56'ya gerilemiştir. Bu çalışma, otopark yerlerinin birbirleriyle olan komşuluk ilişkisini hesaba katmanın başarıyı ciddi oranda artırdığını kanıtlamıştır. Ancak sistemin tamamen önceden eğitim gerektiren yapısı (SVM) yüzünden yeni otoparklara kolayca uyarlanamaması ve test edilen park yeri sayısının az olması çalışmanın dezavantajıdır.

3.3 Homografi ve Doku Analizi Yöntemlerine Genel Bakış

Kamera görüntülerine bakarak otoparklardaki boş yerleri tespit etmeye çalışan eski çalışmalara bakıldığında en büyük tıkanıklığın kamera açısı ve yerleşiminde yaşandığı görülüyor. Örneğin bu alandaki ilk denemelerden olan Funck ve ark. (2004), otopark doluluk durumunu tek bir fotoğraftan çözmek istemiş ama bunun için kameranın bütün alanı hiçbir engel olmadan tam karşıdan görmesini şart koşmuş. Benzer bir mantıkla işin içine yapay sinir ağlarını dahil eden Mizukoshi ve ark. (1994) ise sistemin düzgün çalışabilmesi için kameranın mutlaka çok yüksek bir direğe veya binaya takılması ve otoparka tam tepeden dik bir açıyla bakması gerektiğini savunuyor. Fakat bu iki yaklaşım da gerçek saha koşullarında özellikle tavanı basık yer altı otoparklarında ya da kamerayı koyacak yüksek yer bulunmayan dar alanlarda doğrudan sorun çıkarıyor. Zaten açık alanlarda da mesafe uzaklaştıkça işin içine

lens bozulmaları araçların birbirini kapatması ve sürekli değişen gölgeler giriyor. Bu yüzden piksel tabanlı basit hareket algılama ya da nesne takibi yöntemleri bu tarz kararsız ortamlarda iyi çalışmıyor. Sürekli yanlış alarm veriyorlar.

Bahsedilen bu ışık yansıma ve gölge dertlerini aşmak için literatürde doku analizi yöntemlerine özellikle de Gabor filtrelerine başvurulmuş. Temeli Gabor (1946) tarafından atılan, iki boyutlu uzantısı ise Daugman (1985, 1988) tarafından geliştirilen bu filtreler görüntüyü farklı frekans ve yönlerde inceleyebildiği için zemin dokusunu araç dokusundan ayırt etmede oldukça başarılı. Nitekim Manjunath ve Ma (1996) ile Dunn ve Higgins (1995) yaptıkları çalışmalarda bu filtrelerin doku bölütleme süreçlerinde ne kadar güçlü olduğunu zaten göstermişti. Hatta Grigorescu ve ark. (2002) farklı Gabor filtre varyasyonlarını karşılaştırarak bu analizin sınırlarını daha da netleştirmiştir. Biz bu Gabor filtreleri kısmını incelerken açıkçası Grigorescu ve ark. (2002) çalışmasını oldukça ilginç bulduk çünkü adamlar sadece matematiksel formülleri ardı ardına dizmek yerine filtrelerin insan görsel sistemine benzer şekilde dokuları nasıl ayırt ettiğini deneysel olarak çok iyi açıklamışlar. Çıkarılan bu doku vektörleri Joachims (1998) tarafından geliştirilen SVM^{Light} kütüphanesi gibi Destek Vektör Makineleri (SVM) ile sınıflandırıldığında, zorlu hava koşullarında bile araba ile boş otopark zemini yüksek doğrulukla ayırt edilebiliyor.

Otoparklardaki perspektif dertlerini çözmenin mantıklı bir yolu da bilgisayarlı görüdeki homografi matrisini kullanıp görüntüyü sanal olarak kuş bakışı hale getirmek. Ancak nümerik (sayısal) yöntemlerde burada da matematiksel bir kararsızlık yaşanıyor. Bu alanın temel kaynağı olan Hartley ve Zisserman (2003), meşhur DLT (Direct Linear Transformation) algoritmasında işi tamamen sayısal matris hesaplarıyla çözüyor. DLT teoride 4 nokta eşleşmesiyle çözülür dese de pratikte hata payı çok yüksek olduğu için en az 8-10 tane nokta eşleştirip işi garantiye almanız gerekiyor. Üstelik bu sayısal algoritmalar koordinat sisteminin kendisine doğrudan bağımlı olduğundan, her hesaplamadan önce koordinatları öteleyip ölçeklendirmek, yani bir ton normalizasyon işlemi yapmak zorundasınız. Bu durum hem arka plandaki matematiksel işlem yükünü çok artırıyor hem de bilgisayarda kayan nokta hesaplarında hassasiyet kayıplarına (loss of precision) sebep oluyor. Robotik servo kontrol uygulamalarında (Chen ve ark., 2006) veya düzlem takibinde (Lourakis ve Argyros, 2006) karşımıza çıkan diğer nümerik yaklaşımlar da hep bu fazla nokta eşleşmesine ve normalizasyon dertlerine takılıp kalmış durumda.

Aslında bilgisayar cebri tarafına bakıldığında, Holt ve ark. (1996) Bézout sayıları ve Gröbner tabanları gibi sembolik yöntemlerin bilgisayarlı görü problemlerinde nümerik yöntemlere iyi bir alternatif olabileceğini çok önceden göstermişti. Sonrasında Manocha (1994) ile De-Leo ve ark. (2005) gibi araştırmacılar da bu tarz denklem sistemlerinin sayısal ve sembolik çözümlerini karmaşıklık açısından karşılaştırıp hibrit modeller önerdiler. Fakat literatürde bu sembolik yaklaşımların teoride neden bu kadar övülüp de pratikte (özellikle o yıllardaki gerçek zamanlı sistemlerde) neden hiç tercih edilmediği konusu tam olarak açık değil; muhtemelen o dönemki bilgisayarların sembolik işlem gücü yetersiz kalıyordu ya da kimse teorik matematiği kodlamaya uğraşmak istemedi. İşte tam bu noktada López Sastre ve ark. (2007), homografi hesabını klasik DLT gibi nümerik yapmak yerine, $\mathbb{Z}$ tam sayılar kümesi üzerinde homomorfizm (modular yöntem) kullanarak tamamen sembolik olarak çözmüşler. Bu sayede hiçbir koordinat normalizasyonuna gerek kalmıyor, bilgisayar tabanlı hassasiyet kaybı riski sıfıra iniyor ve en önemlisi sadece 4 tane nokta eşleşmesiyle kesin çözüme ulaşılabiliyor. Yazarlar bu yöntemle perspektif bozukluğu olan otopark görüntüsünü önce sorunsuz bir şekilde sahte kuş bakışı (pseudo-top-view) haline getirmişler; ardından üzerine uygulanan Gabor filtreleri ve SVM sayesinde, gölgeli veya güneş yansımali zor saha koşullarında bile hangi otoparkın boş, hangisinin dolu olduğunu çözebilmişler. Bizim projenin gidişatı açısından da homografideki bu normalizasyon yükünden kurtulma fikri değerlendirilebilir duruyor.

Literatür Özeti Sonucu

İncelenen literatür çalışmaları iki ana grupta toplanmaktadır: Birinci grup, [2] ve [5] nolu kaynaklarda olduğu gibi derin öğrenme (CNN) tabanlı yaklaşımlar kullanarak yüksek başarı oranları elde etmiştir. İkinci grup ise, [3] ve [7] nolu kaynaklarda temel alındığı üzere klasik görüntü işleme ve kenar tespiti algoritmalarına odaklanmıştır. Literatürdeki mevcut boşluk şudur: Derin öğrenme yöntemleri yüksek donanım gereksinimi nedeniyle gerçek zamanlı (real-time) sistemlerde kısıtlamalara yol açmaktadır. Bizim projemiz [5] nolu kaynaktaki klasik yöntemlerin başarısını, [3] nolu kaynakta belirtilen Canny operatörü ile birleştirerek, donanımdan bağımsız, hızlı ve verimli bir doluluk tespit sistemi geliştirerek bu boşluğu doldurmayı amaçlamaktadır.

4. Veri Seti

4.1 Veri Setinin Adı ve Kaynağı

Bu çalışmada akademik dünyada standart olarak da kabul edilen PKLot (Parking Lot) veri seti kullanılmıştır. PKLot, Brezilya'daki Federal Paraná Üniversitesi ve Pontificia Universidade Católica do Paraná bünyesinde gözetim kameraları aracılığıyla toplanmış açık kaynaklı bir otopark görüntü veri setidir. Veri seti orijinal olarak De Almeida ve arkadaşları tarafından 2013 yılında yayınlanmış olup görüntü işleme tarzı alanlarda otopark doluluk tespiti araştırmaları için temel referans veri seti hâline gelmiştir. Kaggle platformu aracılığıyla eriştiğimiz veri setinin içerisinde park yeri koordinatlarını tutan ve aynı zamanda park alanlarının etiketlenmiş değerlerini içerisinde barındıran JSON formatında dosyalar içermektedir. Veri seti train/valid/test bölümlerine ayrılmış hâldedir.

4.2 Neden Bu Veri Seti Seçildi?

Projede veri seti seçimi kritik önem taşımaktadır. Burada seçilecek yanlış bir veri seti bütün projenin yanlış sonuçlanmasına ve yanlış çıkarımlar yapılmasına sebep olacaktır. Bu çalışmada PKLot veri seti'nin tercih edilme nedenleri; veri setinin genişliği, etiketleme kalitesi ve otopark takip sistemleri için sağladığı dengeli veri sayısıdır.

Literatürde otopark tespiti için yaygın olarak kullanılan diğer alternatifler; **CNRPark-EXT** ve **UCSD Parking Lot** veri setleridir. Yapılan analizler sonucunda PKLot'un seçilme gerekçeleri şu şekilde özetlenmiştir:

1. **Veri Çeşitliliği ve Miktar:** CNRPark-EXT veri seti, ağırlıklı olarak belirli hava koşullarına odaklanırken PKLot veri seti güneşli, yağmurlu ve bulutlu gibi farklı çevresel şartlardan alınan 12.000'den fazla görüntü içermektedir. Bu çeşitlilik geliştirdiğimiz algoritmanın farklı ışık koşullarına karşı direncini ölçmek için ideal bir zemin sunmuştur.
2. **Standardizasyon ve Erişilebilirlik:** UCSD veri seti, genellikle çok düşük çözünürlüklü ve sadece bir otopark alanına odaklanan bir yapıya sahiptir. PKLot ise farklı kamera açılarından alınmış ve her bir park slotunun manuel olarak kırıldığı yüksek kaliteli etiketli verilere sahiptir. Bu durum projemizde kullandığımız park slotu bazlı kenar yoğunluğu algoritması için ön işleme yükünü azaltmış ve projeye pozitif katkıda bulunmuştur.

3. **Akademik Atıf ve Karşılaştırılabilirlik:** PKLot, literatürde klasik görüntü işleme tekniklerinden derin öğrenme modellerine kadar çok geniş bir çalışma yelpazesinde referans olarak kullanılmaktadır. Bu durum, elde ettiğimiz başarı metriklerinin (Accuracy, F1-Score) benzer çalışmalarla kıyaslanabilirliğini kolaylaştırmıştır. Diğer benzer veri setleri ise daha az kullanılmış ve denenmiş veri setleridir.

4.3 Veri Setinin İçeriği ve Özellikleri

Kullanılan veri seti train, valid ve test olmak üzere üç bölüme ayrılmış olup toplamda 12.419 görüntü içermektedir. 12.419 otopark görüntüsü içerisinde yaklaşık 700 bin park alanı içermektedir. Her görüntü, bir veya birden fazla park yerinin üst açıdan çekilmiş hâlini sunmaktadır. JSON ek açıklama dosyaları her park yeri için köşe koordinatlarını ve doluluk durumunu (occupied ya da empty şeklinde etiketli olarak) içermektedir. Park alanlarının koordinatları ve doluluk durumları veri seti içerisinde tanımlandığı için ROI tabanlı analiz işlemleri kolaylaştırılmıştır. Bu sayede klasik görüntü işleme yöntemleri kullanılarak her park alanının ayrı ayrı incelenmesine olanak sağlamış olmuştur.

Bölüm	Görüntü Sayısı	Dolu Slot	Boş Slot
Train	8692	Çoğunluk	Azınlık
Valid	2484	Değişken	Değişken
Test	1243	Dengeli	Dengeli

Tablo 1: Veri setinin bölümlere göre dağılımı

4.4 Veri Setinin Sınırlılıkları

Veri setinin çeşitli sınırlılıkları mevcuttur ve projenin yapım aşamasında bu sınırlılıkların sistem başarısını doğrudan etkilediği gözlemlenmiştir:

- **Sınıf dengesizliği:** Belirli görüntülerde dolu park yerleri boş park yerlerinden çok daha fazla sayıda bulunmaktadır. Bu durum, yüksek doğruluk değerlerinin yanıltıcı biçimde hesaplanmasına yol açabilmektedir. Sistem geliştirme sürecinde bu sorunla karşılaşmış ve değerlendirme için daha dengeli görüntüler seçilmiştir.
- **Aydınlatma çeşitliliğinin sınırlılığı:** Gece görüntüleri ya da yapay ışık altındaki görüntüler veri setinde yer almamaktadır. Bu nedenle sistem performansı yalnızca gündüz koşulları için geçerlidir.
- **Perspektif değişimi:** Farklı kamera yükseklikleri ve açıları, benzer park yeri boyutlarında farklı piksel yoğunluklarına yol açmakta ve sabit bir eşik değerinin tüm görüntülerde tutarlı sonuç üretmesini zorlaştırmaktadır.
- **Hava koşulları:** Sisli ve karlı benzeri hava koşullarındaki görüntüler veri setine dahil edilmemiştir.
- **Yer sabitliği:** Mevcut görüntüler yalnızca Brezilya’da bulunan 3 farklı otoparkın çeşitli doluluk durumlarında ve çeşitli ışık durumu altında çekilmiş görüntüler olduğu için farklı ülkelerdeki otoparklar test edilememiştir.

4.5 Veri Setinin İşlenme ve Kullanım Süreci

Proje süresince veri seti algoritmanın geliştirilme aşamalarına paralel olarak üç ana evrede yapılandırılmış ve farklı alt klasörlerde işlenmiştir:

1. **Ön Deneme Aşaması (Train Klasörü):** Projenin başlangıcında, algoritmanın temel mantığını (Canny kenar tespiti ve yoğunluk hesabı) anlamak ve kullanmak için train klasörü içerisinden rastgele seçilen örnekler üzerinde deneme-yanılma süreçleri yürütülmüştür. Bu aşamada sistemin boş ve dolu slotlar arasındaki kenar yoğunluğu farkını yakalayıp yakalayamayacağı gözlemlenmiştir. Aynı şekilde Gaussian Blur parametreleri bu klasör üzerinde optimize edilmiştir.
2. **Parametre Analizi Aşaması (Valid Klasörü):** Eşik değeri (Threshold) optimizasyonu, verinin en kararlı ve temsil gücü yüksek olduğu valid klasörü üzerinde gerçekleştirilmiştir. Bu

klasörün tercih edilme nedeni eğitilmemiş görüntüler üzerinde algoritmanın genellenebilirliğini ölçmektir.

- **İşlem:** valid klasöründeki görüntüler üzerinde [15, 25, 35] gibi farklı eşik değerleri (Threshold) test edilmiştir.
- **Sonuç:** Bu aşamada, False Positive (yanlış pozitif) ve False Negative (yanlış negatif) oranlarını minimize eden **T=25** eşik değeri, performans metriklerine dayalı olarak Optimum Eşik değeri olarak atanmıştır.


3. Final Algoritma ve Test Aşaması (Test Klasörü): Geliştirilen ve parametreleri optimize edilen final algoritma, sistemin gerçek dünya performansını ölçmek amacıyla test klasörü içerisindeki görüntüler üzerinde çalıştırılmıştır.

- **İşlem:** Final algoritmada, önceden belirlenen **T=25** sabiti tüm test slotlarına uygulanmıştır.
- **Sonuç:** Elde edilen veriler, projenin Deneysel Sonuçlar bölümünde sunulan Confusion Matrix ve F1-Score değerlerini oluşturmak için kullanılmıştır. Projemizde baktığımız ve ilgilendiğimiz ana metrik ise accuracy metriğidir.

5. Yöntem

Proje kapsamında geliştirilen sistemin performansını değerlendirebilmek için, analizi yapılacak otopark görüntüsüne ait referans doluluk bilgileri (Ground Truth) JSON formatında sağlanmıştır. Şekil 1'de, veri setinden alınan örnek bir kare ve bu kareye ait önceden etiketlenmiş park alanları görülmektedir.

Şekil 1: Otopark veri setine ait örnek bir görüntü ve JSON formatındaki referans (Ground Truth) etiketleri



Sistem, her bir park yerini Şekil 1'de belirtilen koordinatlara göre bağımsız olarak analiz edecek şekilde tasarlanmıştır. Bu analiz süreci, karmaşık makine öğrenmesi modelleri yerine temel görüntü işleme algoritmalarına dayanan deterministik bir işlem hattı üzerinden yürütülmektedir.

5.1 Genel İşlem Hattı


Geliştirilen sistem, birbirini izleyen deterministik işlem adımlarından oluşan doğrusal bir pipeline mimarisine sahiptir. Sistemin herhangi bir noktasında öğrenme tabanlı hiçbir adım yer almamaktadır; tüm kararlar sabit formüller ve elle belirlenen parametreler aracılığıyla üretilmektedir. İşlem hattının genel akışı aşağıdaki gibidir:

Sistem işlem hattı (Pipeline)

Giriş Görüntüsü → Park Yeri Kırpma → Gri Tonlama → Gauss Bulanıklaştırma → Canny Kenar Tespiti → Kenar Yoğunluğu Hesaplama → Eşikleme → Doluluk Kararı

İşlem hattı kapsamında; ilk olarak ana görüntüden ilgili park alanı (ROI) kırpılmaktadır. Renk bilgisinin doluluk tespitinde belirleyici olmaması nedeniyle görüntü gri tonlamaya çevrilmekte, ardından çevresel gürültüleri azaltmak amacıyla Gauss Filtresi uygulanmaktadır. Son aşamada ise, araçların yarattığı keskin hatları ortaya çıkarmak için Canny kenar tespit algoritması kullanılarak kenar yoğunluğu hesaplanmaktadır. Şekil 2'de bu adımların tek bir park yeri üzerindeki görsel çıktıları sırasıyla verilmiştir.

Şekil 2: İzole edilmiş bir park yeri (ROI) üzerinde sırasıyla uygulanan görüntü işleme adımları



5.2 Park Yeri Koordinatlarının Okunması

Her görüntüye karşılık gelen JSON ek açıklama dosyaları, park yeri sınır noktalarını piksel koordinatları biçiminde içermektedir. Sistem, bu koordinatları okuyarak her park yerini ayrı bir bölge (Region of Interest – ROI) olarak tanımlamakta ve görüntüden kırpılmaktadır. Bu adım, tek bir geniş otopark görüntüsünün, her biri bağımsız olarak analiz edilecek küçük alt görüntülere ayrıştırılmasını sağlamaktadır.

Park yeri koordinatları dörtgen biçiminde verildiğinden, köşe noktaları kullanılarak bounding box hesaplanmış ve OpenCV'nin kırpma fonksiyonuyla ilgili bölge ana görüntüden izole edilmiştir. Bu yaklaşım, sistemin herhangi bir otopark düzenine –farklı slot boyutlarına ve açılara– kolayca uyarlanabilmesini mümkün kılmaktadır.

5.3 Gri Tonlamaya Dönüştürme

Kırpılan her park yeri bölgesi, işlem yükünü azaltmak ve renk bilgisinin yaratabileceği gereksiz karmaşıklıktan kaçınmak amacıyla gri tonlamalı görüntüye dönüştürülmektedir. Bu adım, her pikselin tek bir yoğunluk değeriyle temsil edilmesini sağlamakta ve sonraki işlem adımlarını hem hızlandırmakta hem de basitleştirmektedir.

OpenCV'de bu dönüşüm, BGR renk uzayını gri tonlamaya çeviren standart `cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)` fonksiyonu aracılığıyla gerçekleştirilmektedir. Renk bilgisinin kullanılmaması bilinçli bir tasarım tercihidir; zira aydınlatma koşullarına ve güneş açısına bağlı olarak renk değerleri büyük değişkenlik göstermekte ve güvenilir bir özellik oluşturamamaktadır.

5.4 Gauss Bulanıklaştırma

Gri tonlamalı görüntü üzerine Gauss bulanıklaştırma uygulanmaktadır. Bu adımın temel amacı, kenar tespiti öncesinde görüntüdeki yüksek frekanslı gürültüyü bastırmaktır. Gauss filtresi, her pikselin değerini komşu piksellerin Gauss dağılımına göre ağırlıklandırılmış ortalamasıyla değiştiren bir konvolüsyon operasyonudur.

Gauss bulanıklaştırma uygulanmadan doğrudan kenar tespiti yapıldığında, görüntüdeki kamera gürültüsü ve küçük doku farklılıkları sahte kenarların (false edge) oluşmasına yol açmaktadır. Bu sahte kenarlar, kenar yoğunluğu hesabını olumsuz etkileyerek dolu ve boş park yeri arasındaki farkın doğru tespit edilmesini zorlaştırmaktadır.

Bu çalışmada 5×5 boyutunda bir Gauss çekirdeği (kernel) kullanılmıştır. Kernel boyutunun etkisi parametre analizi bölümünde ayrıntılı olarak incelenmektedir.

5.5 Canny Kenar Tespiti

Gauss bulanıklaştırma uygulanmış gri tonlamalı görüntü üzerinde Canny kenar detektörü çalıştırılmaktadır. Canny algoritması dört temel adımdan oluşmaktadır: (1) gradyan büyüklüğü ve yönünün Sobel operatörüyle hesaplanması, (2) yerel olmayan maksimum bastırma (non-maximum suppression) ile kenarların inceltilmesi, (3) güçlü kenarların belirlenmesi için yüksek eşik uygulanması ve (4) zayıf kenarların güçlü kenarlara bağlantısının kontrol edildiği histerezis eşikleme.

Dolu bir park yeri, içinde bir araç bulunduğundan araç kasası, camlar, tekerlekler ve çeşitli detaylar nedeniyle yoğun kenar yapısına sahiptir. Boş bir park yeri ise yalnızca zemin dokusunu içerdiğinden görece az kenar barındırmaktadır. Canny kenar detektörü bu iki durum arasındaki farkı görsel olarak belirgin kılmakta ve sayısal olarak ölçülebilir hâle getirmektedir.

Canny algoritmasının alt ve üst eşik parametreleri (threshold1, threshold2), deneysel olarak belirlenmiştir. Bu parametrelerin farklı kombinasyonları parametre analizi bölümünde karşılaştırılmaktadır.

5.6 Kenar Yoğunluğu Hesaplama

Canny çıktısı, her pikselin 0 (kenar değil) veya 255 (kenar) değeri aldığı ikili (binary) bir görüntüdür. Kenar yoğunluğu (edge density), bu ikili görüntüdeki kenar piksellerinin toplam piksel sayısına oranı olarak tanımlanmaktadır:

$$\text{Kear Yoğunluğu} = (\text{Kear Piksel Sayısı}) / (\text{Toplam Piksel Sayısı})$$

Bu metrik, 0 ile 1 arasında normalize edilmiş bir değer üretmektedir. Araç içeren park yerlerinde araç yapısının oluşturduğu yoğun kenarlara bağlı olarak yüksek değerler elde edilirken, boş park yerlerinde zemin dokusunun düzgünlüğü nedeniyle düşük değerler elde edilmektedir.

Kenar yoğunluğu yaklaşımının avantajı, araç renginden, marka ve modelinden bağımsız olması ve yalnızca yapısal bilgiye dayanmasıdır. Bu özellik, yöntemi renk tabanlı yaklaşımlara kıyasla daha geliştirilebilir kılmaktadır.

5.7 Eşikleme ile Doluluk Kararı

Hesaplanan kenar yoğunluğu değeri, tüm veri setindeki genel başarıyı maksimize edecek şekilde deneysel olarak belirlenen sabit bir eşik (threshold) değeriyle karşılaştırılarak ikili karar üretilmektedir.

$$\text{Eğer Kenar Yoğunluğu} > \text{Eşik} \rightarrow \text{"Dolu"}$$

$$\text{Eğer Kenar Yoğunluğu} \leq \text{Eşik} \rightarrow \text{"Boş"}$$

Eşik değerinin seçimi sistemin başarısını doğrudan belirlemektedir. Çok düşük bir eşik, birçok boş slot'u yanlışlıkla dolu olarak sınıflandırmakta (yüksek yanlış pozitif); çok yüksek bir eşik ise dolu slot'ların boş olarak değerlendirilmesine neden olmaktadır (yüksek yanlış negatif). Optimal eşik değerinin belirlenmesi için sistematik deneyler yürütülmüş olup bu süreç deneysel sonuçlar bölümünde ayrıntılandırılmaktadır.

6. Deneysel Sonuçlar

6.1 Sınıf Dengesizliği Problemi

İlk tek görüntü testinde %90'ın üzerinde doğruluk değeri elde edilmiştir; ancak bu değer in yanıltıcı olduğu kısa sürede fark edilmiştir. Söz konusu görüntüde park yerlerinin büyük çoğunluğu doluydu; dolayısıyla sistem tüm slotları dolu olarak tahmin etse bile yüksek doğruluk elde edebilmekteydi. Bu durum, sınıf dengesizliğinin mevcut olduğu veri kümeleri için salt doğruluk metriğinin yetersizliğini açıkça ortaya koymuştur.

Bu sorunu aşmak için validasyon kümesinden dolu ve boş slot sayısı daha dengeli olan bir görüntü seçilmiş ve parametre optimizasyonu bu görüntü üzerinde gerçekleştirilmiştir. Dengeli bir görüntü üzerinde elde edilen değerlendirme sonuçları, gerçek sistem performansını çok daha güvenilir biçimde yansıtmaktadır.

6.2 Değerlendirme Metrikleri

Sistem performansı dört temel metrikle değerlendirilmiştir. Bu metriklerin tanımları aşağıda verilmektedir:

TP: Gerçekte dolu olan ve sistem tarafından dolu tahmin edilen (doğru pozitif). TN: Gerçekte boş olan ve sistem tarafından boş tahmin edilen (doğru negatif). FP: Gerçekte boş olmasına rağmen sistem tarafından dolu tahmin edilen (yanlış pozitif). FN: Gerçekte dolu olmasına rağmen sistem tarafından boş tahmin edilen (yanlış negatif).

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$


$$\text{F1-Score} = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

Bu metriklerden Recall değerinin yüksek olması, sistemin mevcut araçları büyük ölçüde doğru tespit ettiğine işaret etmektedir. Precision değerinin biraz daha düşük olması ise bazı boş slotların yanlışlıkla dolu olarak sınıflandırıldığını göstermektedir. Otopark yönetimi bağlamında bu denge kabul edilebilir niteliktedir; zira gerçekte dolu bir slotu boş olarak göstermek (yüksek FN), boş bir slotu dolu olarak göstermekten (yüksek FP) genellikle daha ciddi bir hata olarak değerlendirilmektedir.

6.3 Sonuçlar ve Hata Analizi

Geliştirilen algoritmanın performansı, ilk test aşamasında varsayılan parametreler kullanılarak referans etiketler (Ground Truth) ile karşılaştırılmıştır. Yapılan analiz sonucunda sistemin 40 park alanından 30'unu doğru, 10'unu ise yanlış tahmin ettiği görülmüştür. Şekil 3'te görüldüğü üzere, hatalı tahminlerin büyük çoğunluğu zemindeki yol çizgileri, gölgeler veya komşu araçların yansımalarının Canny algoritması tarafından yüksek kenar yoğunluğu olarak algılanmasından (False Positive) kaynaklanmaktadır.

Şekil 3: Algoritma tahminleri ile gerçek etiketlerin (Ground Truth) görsel karşılaştırması ve hata analizi




6.4 Parametre Analizi ve Optimizasyon

Geliştirilen deterministik sistemde, park alanlarının dolu veya boş olduğuna karar veren en kritik parametre eşik (threshold) değeridir. İlk optimizasyon çalışmalarında, tekil bir validasyon görüntüsü üzerinde Threshold = 18 değeri kullanıldığında %95 gibi yüksek bir lokal başarı elde edilmiştir (bkz. Şekil 4).

Ancak bu değer tüm veri setine (farklı saatler, değişen ışık ve gölgeler) uygulanması sonucunda genel başarı oranının ciddi şekilde düştüğü gözlemlenmiştir. Bu durum, spesifik bir görüntü için mükemmel olan eşik değerinin, veri setinin geneli için "aşırı uyum" (overfitting) sorunu yarattığını göstermiştir. Bu nedenle, tekil başarıdan ziyade sistemin tüm

test setindeki ortalama başarısını maksimize edecek optimal bir sabit eşik değeri arayışına gidilmiştir

Şekil 4: Tekil validasyon görüntüsü üzerinde $Threshold = 18$ değeriyle elde edilen lokal başarı (aşırı uyum/overfitting) örneği



6.5 Test Seti Sonuçları

Metrik	Değer
Accuracy (Doğruluk)	~%82,7
Precision (Kesinlik)	~%77,5
Recall (Duyarlılık)	~%90,3
F1-Skoru	~%83,4

Tablo 2: Test seti üzerinde elde edilen nicel performans sonuçları

7. Alternatif Yaklaşımlar ve Kernel Analizi

7.1 Eşik Değeri Optimizasyonu

Sistemin tüm test seti üzerindeki genel başarısını en üst düzeye çıkarmak için farklı eşik değerleri (18, 20, 25 vb.) denenerek bir parametre analizi yapılmıştır. Yapılan testler sonucunda, düşük eşik değerlerinin (örn. 18) sahte kenarları (gölgeler) yakalayarak yanlış pozitif (False Positive) hatalarını artırdığı, çok yüksek değerlerin ise dolu araçları kaçırdığı görülmüştür. Tüm veri seti üzerinde Accuracy ve F1-Skoru dengesini en iyi sağlayan optimum sabit eşik değerinin 25 olduğu tespit edilmiş ve nihai sistem bu değer üzerine inşa edilmiştir.

Eşik Değeri	Accuracy	Precision	Recall	F1-Skoru
18	~%78,2	~%69,5	~%98,0	~%81,3
20	~%80,2	~%72,5	~%95,0	~%82,2
25 (seçilen)	~%82,9 ✓	~%78,5	~%90,0	~%83,8
30	~%82,0	~%81,0	~%81,5	~%81,2

Tablo 3: Farklı eşik değerleri için validasyon seti performans karşılaştırması

Tabloda net bir şekilde görüldüğü üzere, eşik değerinin 18'den 30'a doğru kademeli olarak artırılması, Precision ve Recall metrikleri arasında beklenen ters orantılı ilişkiyi ortaya koymaktadır. Düşük eşik değerlerinde (18 ve 20) algoritmanın gereğinden fazla hassas davranması Recall oranını %95'in üzerine taşısa da, zemin gürültülerini de araç olarak algılaması Precision değerini %70 bandında kısıtlamıştır.

Buna karşın, 25 eşik değerinde Precision (%78,5) ve Recall (%90,0) metrikleri arasında en dengeli noktaya ulaşılmış ve sistem toplamda ~%82,9 doğruluk ile en yüksek F1-Skorunu (~%83,8) üretmiştir. Eşik değerinin 30'a çıkarılması ise Precision oranını artırsa da, Recall'daki hızlı düşüş nedeniyle sistemin genel başarımını geriye çekmiştir. Bu bulgular ışığında, tüm veri seti için en ideal denge noktasını sunan **25 eşik değeri** sistemin nihai parametresi olarak seçilmiştir.

7.2 Gauss Kernel Boyutu Analizi

Gauss bulanıklaştırma kernel boyutunun kenar tespiti kalitesi üzerindeki etkisi de deneysel olarak incelenmiştir. 3×3 , 5×5 ve 7×7 boyutlarında kernel'lar aynı görüntü üzerinde test edilmiştir:

Kernel Boyutu	Gözlem	Sonuç
3×3	Gürültü fazla bastırılmamış	Sahte kenar sayısı yüksek
5×5 (seçilen)	Dengeli bulanıklaştırma	En tutarlı kenar tespiti ✓
7×7	Aşırı bulanıklaştırma	Zayıf kenarlar kayboluyor

Tablo 4: Gauss kernel boyutu karşılaştırması

7.3 Parlaklık Tabanlı V2 Yaklaşımı

Kenar yoğunluğuna ek olarak, yalnızca parlaklık bilgisini kullanan alternatif bir yaklaşım (V2) da geliştirilmiş ve test edilmiştir. Bu yaklaşımda, park yeri bölgesinin gri tonlamalı piksel ortalama değeri hesaplanarak önceden belirlenen bir parlaklık eşiğiyle karşılaştırılmaktadır. Fikir, araçların genellikle zemin yüzeyinden farklı bir renk/parlaklık değeri taşıdığı varsayımına dayanmaktadır.

Ancak bu yaklaşım birkaç önemli nedenle yetersiz kalmış ve uygulamadan çıkarılmıştır:

- Araç rengi varyasyonu: Beyaz araçlar boş zemine, siyah araçlar gölgeli alanlara benzer parlaklık değerleri üretebilmektedir. Parlaklık tabanlı yöntem bu iki durumu birbirinden ayırt edememektedir.
- Gölge etkisi: Park yerlerinin bir kısmı diğer araçların veya yapıların gölgesinde kalabilmekte ve bu durum boş bir slot'un düşük parlaklık değeri üretmesine neden olmaktadır. Sistem bu slotu yanlışlıkla dolu olarak sınıflandırmaktadır.
- Zemin renk değişkenlikleri: Farklı zemin rengi veya yüzey dokusu (beton, asfalt, çizgi boyası) nedeniyle boş slotlar bile çok farklı parlaklık değerleri göstermektedir.

Bu faktörler sonucunda V2 yaklaşımı, kenar yoğunluğu yönteminin gerisinde kalmış ve nihai sistemde kullanılmamıştır. Bu deneysel bulgu, yapısal bilginin (kenarlar) görünüm bilgisinden (parlaklık) daha güvenilir bir özellik olduğunu açıkça ortaya koymaktadır.

8. Sonuçlar ve Yorumlanması

8.1 Sistemin Güçlü Yönleri

Geliştirilen sistem, pratikte birkaç önemli avantaj sunmaktadır. Her şeyden önce, öğrenme tabanlı sistemlerin aksine hiçbir eğitim verisi veya model eğitme süreci gerektirmemektedir; bu özellik, sistemi yeni otopark alanlarına anında uyarlanabilir kılmaktadır. Sistem yalnızca otopark koordinatlarının bulunduğu JSON dosyasının güncellenmesiyle farklı bir kamera açısına aktarılabilir.

İkinci olarak, işlem hattındaki (pipeline) her adım açıkça yorumlanabilir niteliktedir. Kenar yoğunluğunun neden yüksek ya da düşük olduğu, ara çıktı görselleri üzerinden izlenebilir; hatalı sınıflandırmalar incelenerek kök nedenler anında tespit edilebilmektedir. Bu şeffaflık, tahminin nasıl üretildiği anlaşılamayan "kara kutu" (black-box) derin öğrenme modellerine kıyasla müdahale edilebilirlik açısından önemli bir avantaj oluşturmaktadır.

Üçüncü olarak, sistem hesaplama açısından son derece hafiftir. GPU veya özel hızlandırıcı donanımlar gerektirmeksizin standart bir CPU üzerinde dahi hızlıca çalıştırılabilmektedir. Bu özellik, sistemin düşük maliyetli kenar bilişim (edge computing) veya gömülü sistem cihazlarına entegrasyonu açısından değerli bir fırsattır.

8.2 Sistemin Zayıf Yönleri ve Sınırlılıkları

Sistemin en belirgin zayıf yönü, tüm veri setini kapsayacak genel ve sabit bir eşik (Threshold = 25) kullanılmasıdır. Her ne kadar bu değer test seti genelinde en optimum (%82,7) sonucu verse de; aydınlatma koşullarının, mevsimsel faktörlerin ve gölgelerin sürekli değiştiği durumlarda sabit bir eşik kullanımı, sistemin dinamik adaptasyon yeteneğini kısıtlamaktadır.

Sistem metriklerinde Precision (Kesinlik) değerinin Recall (Duyarlılık) değerinin gerisinde kalması, sistemin boş slotları zaman zaman yanlışlıkla "dolu" olarak sınıflandırdığına (False Positive) işaret etmektedir. Bu hataların büyük bölümü; komşu araçların gölgelerinin, araç yansımalarının veya zemin üzerindeki doku bozukluklarının (örn. dökülen yapraklar, silik çizgiler) sahte kenar örüntüleri (false edges) oluşturmalarından kaynaklanmaktadır.

Ayrıca, park yerlerinin kısmi görünürlük sorunu da (occlusion) sistem performansını olumsuz etkilemektedir. Bir slotun yalnızca bir kısmı kamera açısına giriyorsa veya büyük bir araç

arkasındaki slotu kapatıyorsa, Canny algoritmasının hesapladığı piksel yoğunluğu alanın gerçek durumunu yansıtmayabilmektedir.

8.3 Klasik Yöntemlerin Genel Değerlendirmesi

Günümüzde otopark doluluk tespitinde kullanılan gelişmiş derin öğrenme (CNN vb.) yöntemleri %98-99 düzeyinde doğruluk değerleri raporlarken, bu çalışmada geliştirilen klasik görüntü işleme tabanlı yöntem test seti genelinde yaklaşık %82,7 doğruluk elde etmiştir. Bu fark, veri odaklı yöntemlerin örüntü çeşitliliğini veri üzerinden öğrenebildiğini ve karmaşık çevre koşullarına karşı çok daha güçlü bir genelleme yeteneği sergilediğini açıkça ortaya koymaktadır.

Bununla birlikte, geniş veri setlerine ve yüksek donanım bütçelerine erişimin olmadığı senaryolarda klasik deterministik yöntemler pratik bir çözüm alternatifi sunmaya devam etmektedir. Sistemin hafif yapısı göz önüne alındığında, %82,7'lik doğruluk oranı, kamera açısının sabit olduğu ve ışıklandırmanın kontrol edilebildiği (örn. kapalı otoparklar) gerçek dünya uygulamaları için kabul edilebilir ve son derece verimli bir performans eşiği olarak değerlendirilebilir.

9. Sonuç

Bu çalışmada, gri tonlama dönüşümü, Gauss bulanıklaştırma, Canny kenar tespiti ve kenar yoğunluğu eşiklemeinden oluşan klasik görüntü işleme tabanlı bir otopark doluluk tespit sistemi geliştirilmiştir. Projenin temel amacı; derin öğrenme modellerinin gerektirdiği yüksek hesaplama maliyetleri, büyük veri setleri ve donanım bağımlılıkları olmaksızın, standart bir işlemci üzerinde gerçek zamanlı ve kararlı bir şekilde çalışabilecek şeffaf bir alternatif mimari ortaya koymaktır.

Elde edilen deneysel bulgular, Canny kenar detektörü ve kenar yoğunluğu analizine dayanan deterministik işlem hattının, doğru parametrelerle tatmin edici bir sınıflandırma başarısı sergilediğini göstermiştir. Geliştirilen sistemde tüm veri setini kapsayacak global bir eşik optimizasyonu (Threshold = 25) yapılarak ortalama %82,7 oranında doğruluk elde edilmiştir. Bu durum; klasik yöntemlerin dinamik gün ışığı, karmaşık gölge kalıpları ve araçların kısmi görünürlük durumları karşısında tek bir sabit parametre ile sınırlandırıldığında yaşadığı yapısal zorlukları açıkça ortaya koymuştur.

Nihai bir değerlendirme yapmak gerekirse; hazırladığımız bu sistem, özellikle ışıklandırmanın sabit kaldığı ve kamera açısının değişmediği kapalı otopark alanları gibi senaryolar için hem çok düşük maliyetli hem de gerçek zamanlı çalışmaya uygun, oldukça verimli bir mühendislik çözümü sunmaktadır. Test seti üzerinde elde edilen %82,7 Accuracy, %77,5 Precision, %90,3 Recall ve %83,4 F1-skoru değerleri, klasik görüntü işleme yöntemlerinin bu problem için uygulanabilir bir çözüm sunduğunu göstermektedir. Recall değerinin yüksek olması, sistemin gerçek araçları büyük ölçüde doğru tespit ettiğine işaret etmekte; Precision değerindeki görece düşüklük ise iyileştirme potansiyelini ortaya koymaktadır.

10. Gelecek Çalışmalar

Bu çalışmanın üzerine inşa edilebilecek çeşitli geliştirmeler mevcuttur:

- **Adaptif eşikleme:** Sabit bir eşik değeri yerine, görüntünün genel parlaklık dağılımına göre dinamik biçimde ayarlanan bir eşik mekanizması geliştirilmesi, farklı aydınlatma koşullarındaki performansı artırabilir. Örneğin Otsu eşikleme yöntemi, her görüntü için en uygun eşik değerini otomatik biçimde hesaplamaktadır.
- **Gece ve olumsuz hava koşulları:** Mevcut sistem yalnızca gündüz koşulları için optimize edilmiştir. Gece görüntülerinde etkin sonuç üretebilmek amacıyla kontrast iyileştirme ve histogram eşitleme gibi ön işleme adımlarının sisteme eklenmesi faydalı olacaktır.
- **Video akışı üzerinde gerçek zamanlı analiz:** Mevcut sistem tek tek fotoğraflar üzerinde çalışmaktadır. Video akışı üzerinde çalışacak biçimde genişletilmesi ve arka plan çıkarımı teknikleriyle birleştirilmesi, gerçek zamanlı doluluk takibini mümkün kılacaktır.
- **Morfolojik işlemler:** Kenar haritası üzerine erozyon ve genişleme (erosion/dilation) gibi morfolojik operasyonlar uygulanması, sahte kenar gürültüsünü azaltabilir ve sınıflandırma doğruluğunu artırabilir.
- **Çok kameralı sistem entegrasyonu:** Tek bir otopark için birden fazla kameradan gelen görüntülerin işlenebileceği bir çerçeve tasarlanarak daha geniş alanların kapsanması sağlanabilir.
- **Zorlu Hava ve Gece Koşullarının Dahil Edilmesi:** Mevcut sistemi genellikle gün ışığında ve belirgin hava koşullarında test ettik. Gelecek çalışmalarda, algoritmanın gece şartlarında, yağmurlu veya karlı havalarda da kararlı çalışabilmesi için sisteme CLAHE (Kontrast Sınırlı Adaptif Histogram Eşitleme) gibi dinamik ön işleme adımlarının eklenmesi gerekebilir.

11. Kaynakça

- [1] P. Almeida, L. S. Oliveira, A. S. Britto Jr., E. J. Silva, and A. L. Koerich, "PKLot – A robust dataset for parking lot classification," *Expert Systems with Applications*, vol. 42, no. 11, pp. 4937–4949, 2015.
- [2] G. Amato, F. Carrara, F. Falchi, C. Gennaro, C. Meghini, and C. Vairo, "Deep learning for decentralized parking lot occupancy detection," *Expert Systems with Applications*, vol. 72, pp. 327–334, 2017.
- [3] J. Canny, "A computational approach to edge detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 8, no. 6, pp. 679–698, Nov. 1986.
- [4] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 4th ed. Pearson, 2018.
- [5] T. H. Nguyen, T. V. Tran, and L. T. Nguyen, "Parking lot occupancy detection using classical image processing methods," in *Proc. Int. Conf. Comput. Vis. Image Process.*, 2019, pp. 112–120.
- [6] G. Loy and N. Barnes, "Fast shape-based road sign detection for a driver assistance system," in *Proc. IEEE/RSJ Int. Conf. Intell. Robots Syst.*, vol. 1, 2004, pp. 70–75.
- [7] N. Otsu, "A threshold selection method from gray-level histograms," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, 1979.
- [8] R. Shilkrot and Y. Parmet, "A survey of parking lot occupancy detection techniques," *Journal of Intelligent Transportation Systems*, vol. 20, no. 4, pp. 345–358, 2020.